

# Composer 1000genome na Nextflow


Od pytania badawczego do uruchomionego workflow'u — agentowe AI dla nauki

Rozwija composer HyperFlow (Balis i in., AGH / Sano)

*Rafał Szepieniec*

- ▶ Composer = agent: pytanie w języku naturalnym → uruchamialny workflow naukowy
- ▶ Ten sam ResearchIntent napędza DWA silniki: HyperFlow i Nextflow
- ▶ Wynik naukowo IDENTYCZNY niezależnie od silnika
- ▶ Composer to specjalista domenowy; silnik to wymienny backend

Od pytania badawczego do uruchomionego workflow'u - composer 1000genome / Nextflow



Mów: Pięć etapów. Tylko pierwszy używa LLM — reszta deterministyczna. LLM konfiguruje, ale nie dotyka danych.

| Etap      | Co robi                                 | Co powstaje                       |
|-----------|-----------------------------------------|-----------------------------------|
| INTERPRET | LLM + skille strukturyzują pytanie      | intent (populacje, region, focus) |
| MAP       | intent → parametry i adresy do pobrania | --populations, extract.csv        |
| EXTRACT   | tabix pobiera region z 1000 Genomes     | VCF (tylko potrzebny kawałek)     |
| DAG       | 5 skryptów naukowych w kontenerach      | macierze mutacji, częstości       |
| WYNIKI    | pakowanie per (chromosom × populacja)   | chrN-POP.tar.gz + wykresy         |

Mów: Region „BRCA1” zamienia się na współrzędne, tabix pobiera tylko ten fragment, dalej idzie oryginalny DAG 1000genome.

| Optymalizacja                                            | Gdzie występuje                              |
|----------------------------------------------------------|----------------------------------------------|
| Scatter-gather (równoległość individuals)                | oba silniki (Nextflow: natywnie na kanałach) |
| Ekstrakcja tabix — tylko region (~50× mniej transferu)   | oba silniki                                  |
| Cache obrazów kontenerów                                 | oba silniki                                  |
| Automatyczne raporty wykonania (timeline, report, trace) | tylko Nextflow                               |
| Wznawianie -resume (pomija zadania już policzone)        | tylko Nextflow                               |

Mów: Część optymalizacji jest wspólna dla obu silników; raporty i wznawianie -resume to cechy specyficzne dla Nextflow.

| Skill                | Wiedza domenowa                                     |
|----------------------|-----------------------------------------------------|
| SKILL.md             | rola i rekomendowany workflow                       |
| populations.md       | kody populacji 1000G (AFR, EUR, EAS...) + licznosci |
| genomic-regions.md   | geny → współrzędne (BRCA1, BRCA2, HLA)              |
| research-contexts.md | choroba → sugerowany region                         |
| data-sources.md      | wzorce URL 1000 Genomes (FTP/S3/GCS)                |

Mów: Kluczowy `genomic-regions.md` — dzięki niemu „BRCA1” staje się współrzędnymi. Te same skille obsługują oba silniki.

| Zreusowane 1:1                            | Dostosowane / nowe                                  |
|-------------------------------------------|-----------------------------------------------------|
| interpreter LLM, ResearchIntent, 5 skilli | backend composer.py (intent → params + extract.csv) |
| 5 skryptów naukowych + obraz worker       | DAG main.nf w Nextflow DSL2 (kanały)                |
| URL-e tabix (1000 Genomes)                | obraz worker-nf (+bash), runner nextflow run        |

*Mów: Cały mózg i cała nauka poszły 1:1. Dostosować trzeba było tylko sposób opisania DAG-u i uruchomienia — ok. 2 nowe pliki.*

| Faza         | Różni się? | Charakter różnicy                                                                                                |
|--------------|------------|------------------------------------------------------------------------------------------------------------------|
| 1. INTERPRET | nie        | Wspólny komponent interpretacji (LLM + skille); intent identyczny                                                |
| 2. MAP       | częściowo  | HyperFlow generuje materializowany graf workflow.json; Nextflow: statyczny opis (main.nf) + parametry runtime    |
| 3. EXTRACT   | częściowo  | Ta sama metoda (tabix, te same źródła); różni się umiejscowienie kroku i pomiar wolumenu danych                  |
| 4. EXECUTE   | zasadniczo | Model równoległości: HyperFlow kalibruje liczbę zadań po pomiarze; Nextflow rozwija graf dynamicznie na kanałach |
| 5. WYNIKI    | nie        | Artefakty identyczne; Nextflow dodatkowo generuje raporty wykonania automatycznie                                |

*Mów: Warstwa interpretacji jest wspólna. Różnice koncentrują się w sposobie opisu grafu i modelu równoległości — wynik identyczny.*



- ▶ Wyekstrahowany VCF: ~2369 wierszy (wariantów)
- ▶ Dzielimy na kawałki (np. 10) → 10× individuals liczonych RÓWNOLEGLE (scatter)
- ▶ individuals\_merge scala 10 wyników w jeden (gather)
- ▶ W Nextflow: wzorzec opisany raz w main.nf; silnik sam tworzy N zadań z przepływu danych (kanały)
- ▶ workflow.json (HyperFlow) nie jest w tym podejściu używany — to alternatywa, nie wąskie gardło

| Podejście          | Jak dobiera liczbę zadań J                                                            |
|--------------------|---------------------------------------------------------------------------------------|
| HyperFlow          | „zmiar → dobierz J” automatycznie: 136 wierszy → J=1, 166 tys. → J=51 (nie przesadza) |
| Nextflow (obecnie) | J z parametru --ind_jobs (domyślnie 10) — stałe, ustawiane ręcznie                    |
| Nextflow (możliwe) | proces liczy wiersze → dynamiczny podział; operatory splitText/splitFastq             |

**Auto-kalibracja nie jest wbudowana w Nextflow — wymaga dodania (proces mierzący wolumen). Dobry następny krok.**

| Prompt (pełny)                                                                                                                                                                                                      | HyperFlow (oczekiwany)                               | Nextflow                                     | ✓ |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------|----------------------------------------------|---|
| Do European and African populations show different patterns of shared deleterious mutations on chromosome 22? This is relevant for understanding population-specific disease risks.                                 | comparison · [EUR,AFR] · chr22 · deleterious         | comparison · [EUR,AFR] · chr22 · deleterious | ✓ |
| What is the genome-wide null distribution of mutation sharing across all populations? This provides the statistical baseline needed to evaluate whether disease-associated mutations show unusual sharing patterns. | multi · [AFR,ALL,AMR,EAS,EUR,GBR,SAS] · all_variants | multi · [AFR,AMR,EAS,EUR,SAS] · all_variants | ~ |
| Do East Asian populations show distinct mutation sharing patterns in the HLA immune region that could explain population-specific autoimmune disease susceptibilities?                                              | region · [EAS] · HLA · all_variants                  | region · [EAS] · HLA · all_variants          | ✓ |

Mów: Interpreter jest WSPÓŁDZIELONY (import z HyperFlow). To test reużycia i zmienności LLM — nie różnicy silników. Kolumna HyperFlow = expected\_intent z cases.yaml.


| Prompt (pełny)                                                                                                                                                                                  | HyperFlow (oczekiwany)                                     | Nextflow                                                   | ✓ |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------|------------------------------------------------------------|---|
| Compare the patterns of genetic variation between European and African populations in the HLA region. Are there population-specific variants that might explain differences in immune response? | comparison · [EUR,AFR] · HLA · all_variants                | comparison · [EUR,AFR] · HLA · all_variants                | ✓ |
| What variants exist in the BRCA1 and BRCA2 breast cancer genes across different populations? Are there population-specific patterns that might inform targeted screening recommendations?       | multi · [AFR,EUR,EAS,SAS,AMR] · BRCA1,BRCA2 · all_variants | multi · [AFR,AMR,EAS,EUR,SAS] · BRCA1,BRCA2 · all_variants | ✓ |
| Analyze BRCA1 gene variants in the British population.                                                                                                                                          | region · [GBR] · BRCA1 · all_variants                      | region · [GBR] · BRCA1 · all_variants                      | ✓ |

5/6 identycznych — jedyna różnica to zmienność LLM (genome-wide: ALL, GBR). Interpreter jest ten sam kod.

Ten sam prompt (BRCA1, GBR) → HyperFlow vs Nextflow → porównanie bit-do-bit (md5) 4002 plików

| Kategoria wyników                             | Identyczne | Różne |
|-----------------------------------------------|------------|-------|
| Histogramy mutation_overlap                   | 1000       | 0     |
| Mutation_overlap + pozostałe deterministyczne | 2000       | 0     |
| map_variations, mutation_index                | 2          | 0     |
| random_indiv (losowe próbki)                  | 0          | 1000  |

**3002/4002 deterministycznych wyników identycznych bit-do-bit. 1000 różnic = random.sample BEZ seed → losowość skryptu, niezależna od silnika (dwa runy HyperFlow też by się różniły).**



Mów: Warianty na gen (deterministyczny wynik) — HyperFlow i Nextflow identyczne (md5 zgodny). Histogramy mutation\_overlap są zerowe, bo region BRCA1 jest mały — stąd wcześniejsze puste wykresy.

| Aspekt                                 | Ustalenie                                                                        |
|----------------------------------------|----------------------------------------------------------------------------------|
| Równoważność (wyniki deterministyczne) | 3002/4002 identyczne BIT-DO-BIT (md5) — port nie zmienia nauki                   |
| 1000 plików różnych                    | wyłącznie random_indiv — random.sample BEZ seed; niezależne od silnika           |
| Histogramy mutation_overlap            | zerowe — analiza liczy współdzielenie mutacji SZKODLIWYCH (rzadkie z natury)     |
| Niezerowe histogramy                   | wymagają skali genome-wide → klaster (pełne HLA = VCF 1,69 GB → OOM na laptopie) |


**Równoważność UDOWODNIONA** na danych deterministycznych. **Zerowe histogramy to własność analizy (biologia) + limit laptopa, nie błąd portu. Skala genome-wide = osobny etap na klastrze.**

Prompt: „Analyze BRCA1 gene variants comparing European and African populations”

| Proces                         | Czas         | %CPU |
|--------------------------------|--------------|------|
| EXTRACT (tabix)                | 26 s         | 3%   |
| INDIVIDUALS ×10 (RÓWNOLEGLE)   | ~2 min każde | ~93% |
| INDIVIDUALS_MERGE              | 31 s         | 31%  |
| SIFTING                        | <1 s         | 77%  |
| MUTATION_OVERLAP ×2 (EUR, AFR) | 8 s          | 53%  |
| FREQUENCY ×2 (EUR, AFR)        | 51 s         | 80%  |

**18 zadań, 0 błędów — 10 zadań individuals liczonych naraz (widać równoległość)**





Mów: To samo widać w raporcie na żywo ([timeline.html](#)). Individuals liczą się równolegle; przy limicie ~8 CPU część czeka na wolny slot — realna równoległość.

| Populacje | Region                       | Pliki wynikowe |
|-----------|------------------------------|----------------|
| EUR, AFR  | BRCA1                        | 4              |
| EAS, SAS  | (dane testowe)               | 4              |
| GBR, EUR  | (dane testowe)               | 4              |
| EUR, AFR  | BRCA1 + BRCA2 (multi-region) | 8              |

Różne populacje, single i multi-region. Liczba plików = regiony × populacje × 2 analizy.

BRCA1 (EUR+AFR) vs BRCA1+BRCA2 (EUR+AFR) — ten sam sprzęt (laptop)

| Metryka                  | single (BRCA1) | multi (BRCA1+BRCA2) | wzrost |
|--------------------------|----------------|---------------------|--------|
| Liczba zadań             | 18             | 36                  | ×2     |
| Praca CPU (suma)         | 23 min         | 47,5 min            | ×2     |
| Wall-clock (realny czas) | 6,3 min        | 9,1 min             | ×1,4   |

Rozkład zadań multi-region: EXTRACT ×2 · INDIVIDUALS ×22 · MERGE ×2 · SIFTING ×2 · MUTATION\_OVERLAP ×4 · FREQUENCY ×4 (regiony × populacje)

**Zadania i praca CPU podwajają się, ale wall-clock rośnie tylko 1,4× — skalowanie sublinearne dzięki równoległości.**

- ▶ GOTOWE: weryfikacja równoważności (md5) + reuse interpretera + realny run z metrykami i osią czasu
- ▶ Dyrygent: bramka zatwierdzenia (podgląd planu przed uruchomieniem) + routing między composerami
- ▶ Automatyczny dobór liczby zadań (ind\_jobs) — w Nextflow do dodania (proces mierzący wolumen)
- ▶ Benchmark na wspólnym klastrze; obsługa chrX/chrY w ekstrakcji